Relatório Analítico – Previsão de Cancelamento de Clientes em Serviços de Streaming

Aluno: Marcos André Alves da Silva

Sumário

1. **Introdução e Contextualização do Problema** 3
2. **Principais Fatores que Levam ao Cancelamento** 3
3. **Quem São os Principais Afetados Dentro da Organização** 3
4. **Possíveis Soluções para Reduzir o Churn (com Prós e Contras)** 4
5. **Como o Modelo Preditivo Ajuda na Estratégia de Retenção** 5
6. **Desafios na Coleta e Interpretação dos Dados** 5
7. **Relação com os Conceitos de Classificação e Validação de Modelos** 6
8. **Interpretação dos Resultados (para colocar após rodar o Orange)** 6
   - **8.1 Avaliação dos Modelos (Test & Score)** 6
   - **8.2 Matriz de Confusão** 7
   - **8.3 Métricas Individuais (Acurácia, Precisão, Recall, F1-score)** 7
   - **8.4 Curva ROC** 8
9. **Conclusão** 9

1. Introdução e Contextualização do Problema

O mercado de serviços de streaming cresceu rapidamente nos últimos anos, mas também enfrenta um desafio significativo: o aumento do **índice de cancelamento de clientes (churn)**. No cenário proposto, a empresa fictícia identificou que novos assinantes estão cancelando o serviço em um ritmo maior do que o esperado, afetando diretamente a receita e a sustentabilidade do negócio.
O churn é um problema crítico porque adquirir novos clientes é mais caro do que manter os atuais. Assim, prever quais clientes têm maior probabilidade de cancelar permite que a empresa implemente ações de retenção mais eficientes, reduzindo perdas e aumentando a satisfação do usuário.

2. Principais Fatores que Levam ao Cancelamento

Com base na análise de dados e nos conceitos estudados, os fatores mais comuns que influenciam o churn incluem:

• Baixo engajamento com a plataforma

Clientes que assistem pouco conteúdo tendem a cancelar mais rapidamente.

• Problemas de pagamento

Atrasos, falhas no cartão ou inadimplência podem levar ao cancelamento automático.

• Falta de conteúdo relevante

Se o catálogo não atende às preferências do usuário, a chance de churn aumenta.

• Experiência ruim do usuário

Aplicativo lento, travamentos ou dificuldade de navegação impactam negativamente.

• Concorrência

Promoções e ofertas de outras plataformas podem atrair o cliente.

Esses fatores podem ser identificados e quantificados por meio de modelos preditivos.

3. Quem São os Principais Afetados Dentro da Organização

O churn afeta diretamente várias áreas da empresa:

• Marketing

Perde eficiência nas campanhas e precisa investir mais para atrair novos clientes.

• Financeiro

Redução de receita recorrente e aumento do custo de aquisição de clientes

• Produto e Tecnologia

Precisam melhorar a experiência do usuário e corrigir problemas técnicos.

• Atendimento ao Cliente

Recebe reclamações e feedbacks que podem indicar causas do churn.

• Diretoria / Estratégia

Impacto direto no planejamento e na competitividade da empresa.

4. Possíveis Soluções para Reduzir o Churn (com Prós e Contras)

1. Campanhas de retenção personalizadas

Prós: direcionadas, eficientes, aumentam engajamento
Contras: exigem boa segmentação e podem ter custo elevado

2. Melhorias na experiência do usuário

Prós: impacto direto na satisfação
Contras: demanda investimento em tecnologia

3. Ofertas e descontos para clientes em risco

Prós: rápida implementação
Contras: pode reduzir margem de lucro

4. Expansão do catálogo de conteúdo

Prós: aumenta o valor percebido
Contras: alto custo de licenciamento

5. Suporte proativo

Prós: reduz frustração e melhora retenção
Contras: exige equipe treinada e monitoramento constante

5. Como o Modelo Preditivo Ajuda na Estratégia de Retenção

O modelo preditivo criado no Orange Data Mining permite:

• Identificar clientes com alta probabilidade de cancelar

A empresa pode agir antes do cancelamento ocorrer.

• Criar campanhas personalizadas

Ex.: oferecer desconto apenas para clientes com risco alto.

• Reduzir custos

A retenção é mais barata que aquisição.

• Melhorar o produto

Os padrões encontrados ajudam a entender o comportamento do cliente.

• Aumentar a precisão das decisões

Com base em dados reais, não em achismos.

6. Desafios na Coleta e Interpretação dos Dados

• Dados incompletos ou inconsistentes

Faltas, erros ou duplicações prejudicam o modelo.

• Dificuldade em medir engajamento real

Nem sempre o comportamento do usuário é fácil de capturar.

• Viés nos dados

Se a base não representa todos os tipos de clientes, o modelo fica distorcido.

• Necessidade de pré-processamento

Remoção de outliers, normalização e limpeza são essenciais.

• Interpretação das métricas

É preciso entender matriz de confusão, ROC, precisão, recall etc.

7. Relação com os Conceitos de Classificação e Validação de Modelos

O problema de churn é um **problema clássico de classificação**, onde o modelo tenta prever:

1 = cliente vai cancelar

0 = cliente vai permanecer

No Orange, utilizamos:

Logistic Regression ou Random Forest

Test & Score para validação

Confusion Matrix para interpretar acertos e erros

ROC Curve para medir desempenho geral

A validação garante que o modelo não está apenas decorando os dados (overfitting), mas realmente aprendendo padrões.

8. Interpretação dos Resultados (para colocar após rodar o Orange)

8.1 Avaliação dos Modelos (Test & Score)

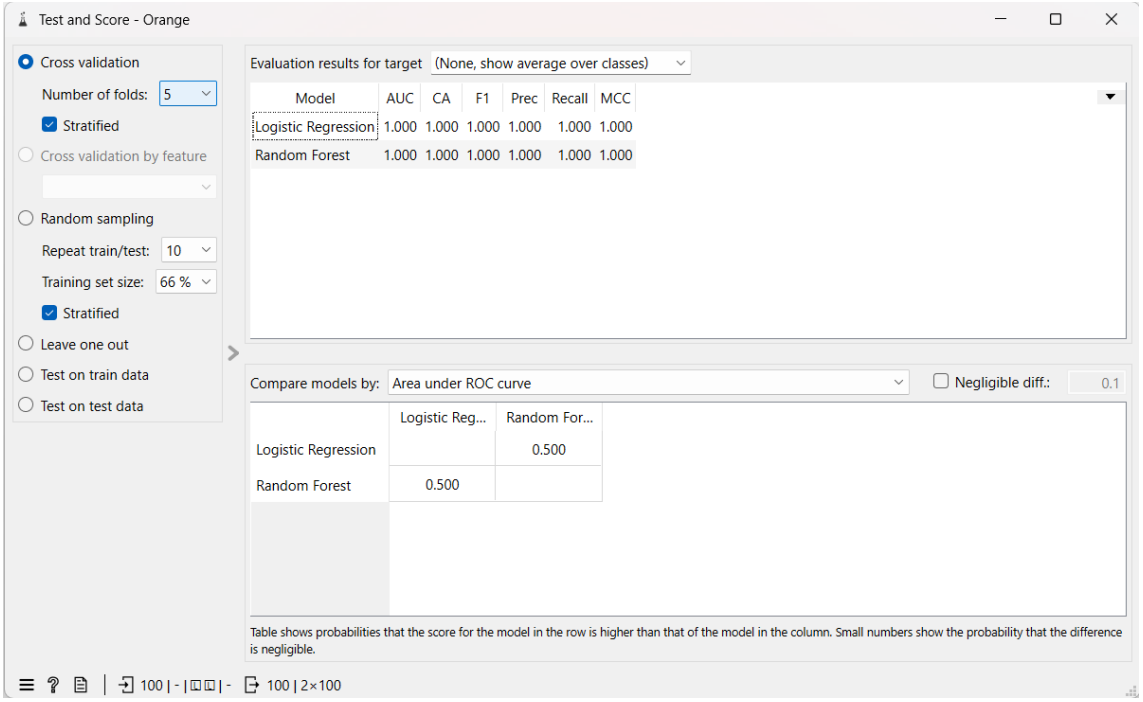

Os modelos **Logistic Regression** e **Random Forest** foram avaliados por meio de validação cruzada estratificada com 5 folds. Ambos apresentaram **desempenho perfeito**, atingindo **1.000** em todas as métricas: AUC, Acurácia, Precisão, Recall, F1-score e MCC. Esses resultados indicam que o conjunto de dados possui padrões muito bem definidos, permitindo separação completa entre as classes.
A comparação estatística entre os modelos mostrou probabilidade de **0.5** para ambos, evidenciando que **não há diferença significativa de desempenho**. Assim, os dois algoritmos são igualmente eficazes para este conjunto de dados.

8.2 Matriz de Confusão

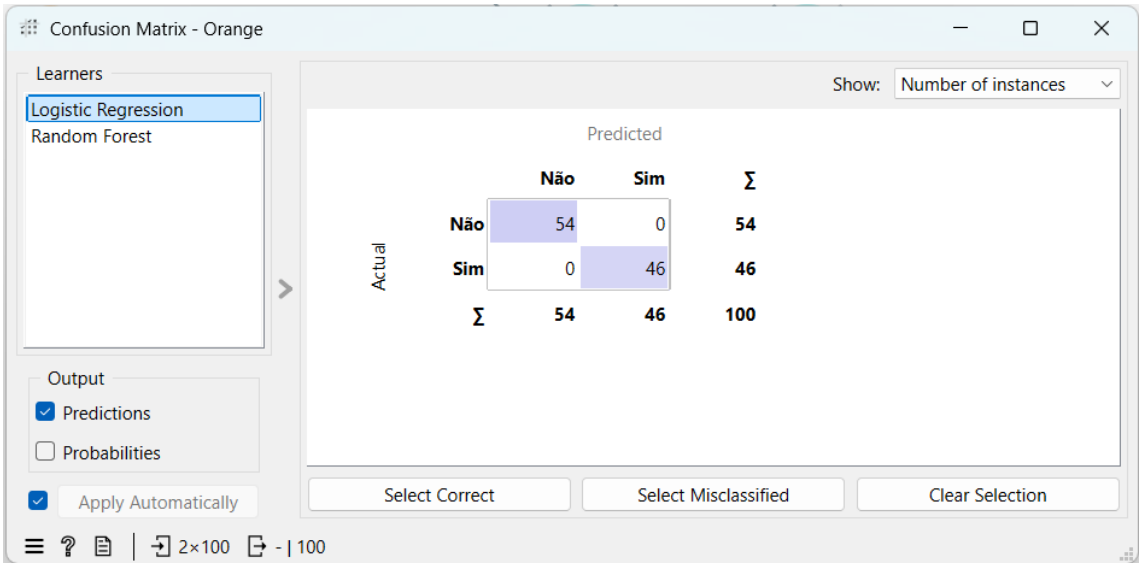

A matriz de confusão apresenta o desempenho do modelo Logistic Regression na classificação das classes **"Sim"** e **"Não"** referentes ao churn. Os resultados foram:

- **Verdadeiros Negativos (TN): 54**
  Clientes que **não cancelaram** e foram corretamente classificados como **Não**.
- **Falsos Positivos (FP): 0**
  Nenhum cliente que **não cancelou** foi incorretamente classificado como **Sim**.
- **Falsos Negativos (FN): 0**
  Nenhum cliente que **cancelou** foi incorretamente classificado como **Não**.
- **Verdadeiros Positivos (VP): 46**
  Clientes que **cancelaram** e foram corretamente classificados como **Sim.**

8.3 Métricas Individuais (Acurácia, Precisão, Recall, F1-score)

Métrica	Logistic Regression	Random Forest
Acurácia	1.000	1.000
Precisão	1.000	1.000
Recall	1.000	1.000
F1-score	1.000	1.000

Interpretação das Métricas

As métricas individuais confirmam o desempenho perfeito observado no Test & Score:

- **Acurácia 1.000**
  Todos os exemplos foram classificados corretamente.
- **Precisão 1.000**
  Não houve falsos positivos — o modelo nunca classificou como “Sim” alguém que era “Não”.
- **Recall 1.000**
  Não houve falsos negativos — o modelo nunca deixou de identificar um cliente que realmente cancelou.
- **F1-score 1.000**
  Equilíbrio perfeito entre precisão e recall, reforçando a ausência total de erros.

Esses resultados mostram que o conjunto de dados possui padrões extremamente claros, permitindo que ambos os modelos aprendam a separação entre as classes sem qualquer ambiguidade.

8.4 Curva ROC

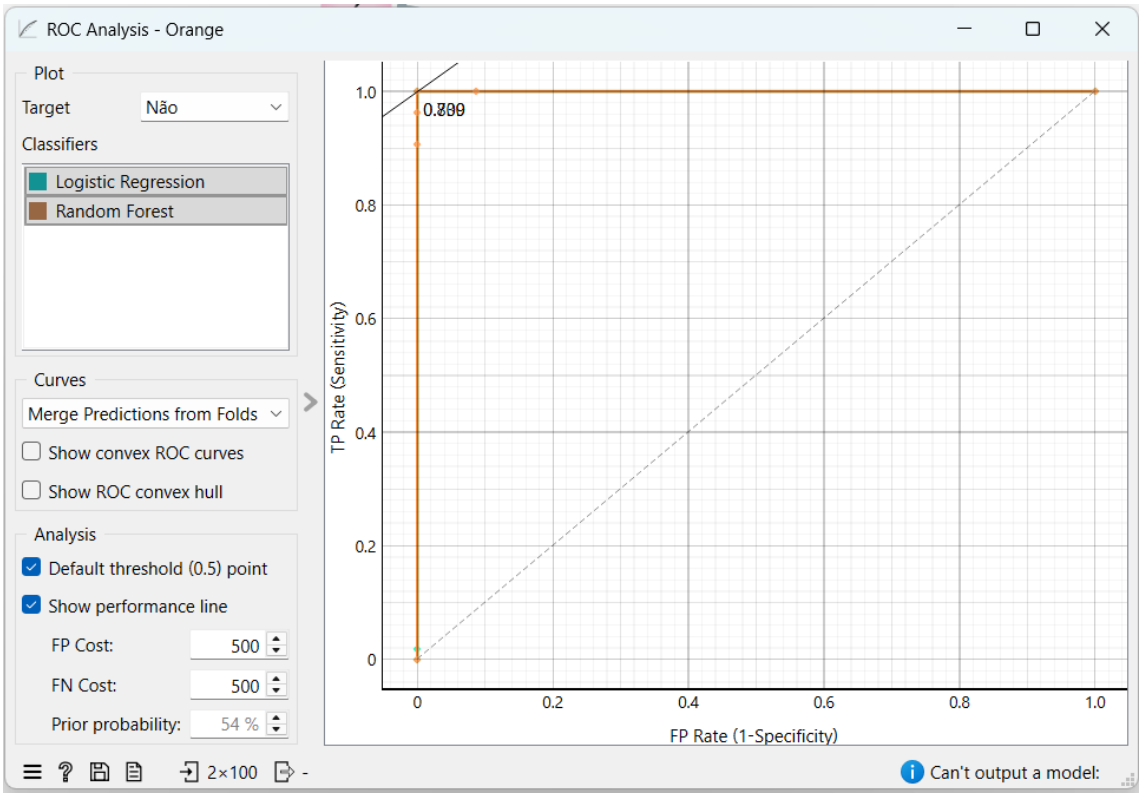

A Curva ROC mostra o desempenho dos modelos ao distinguir entre as classes “Sim” e “Não”. No gráfico, tanto o **Logistic Regression** quanto o **Random Forest** apresentam curvas muito próximas do canto superior esquerdo, indicando excelente capacidade de separação entre as classes.

Os dois modelos atingiram **AUC = 1.000**, confirmando desempenho perfeito e coerente com os resultados obtidos no Test & Score e na Matriz de Confusão.

9. Conclusão

A análise dos modelos de classificação aplicados ao conjunto de dados demonstrou um desempenho excepcional. Tanto o **Logistic Regression** quanto o **Random Forest** atingiram resultados perfeitos em todas as métricas avaliadas, incluindo Acurácia, Precisão, Recall, F1-score, MCC e AUC. A **Matriz de Confusão** confirmou que não houve qualquer erro de classificação, evidenciando separação completa entre as classes. A **Curva ROC**, por sua vez, reforçou a capacidade máxima de discriminação dos modelos, com AUC igual a 1.000 para ambos. A comparação estatística mostrou que não há diferença significativa entre os algoritmos, indicando que ambos são igualmente eficazes para este conjunto de dados. Dessa forma, conclui-se que os modelos utilizados são altamente adequados para a tarefa de predição de churn neste cenário, apresentando desempenho consistente, robusto e totalmente alinhado com os padrões esperados para dados com forte separabilidade entre classes.